



RESUMEN EJECUTIVO

Identificación espacio-temporal de compuestos nutracéuticos en ganado lechero mediante inteligencia artificial

Instituto Tecnológico y de Estudios Superiores de Monterrey

Profesor: **Dr. Horacio Martínez Alfaro**

Integrantes:

Oscar Luis Guadarrama Jiménez - A01796245

Luis Alejandro Juárez Rodríguez - A01795463

José Manuel Pérez González - A01795188

1. Síntesis del Problema

La industria ganadera lechera enfrenta una presión dual: aumentar la producción eficiente de leche mientras reduce su impacto ambiental. El ganado bovino es responsable del 14.5% de las emisiones globales de gases de efecto invernadero (GEI), siendo el metano entérico (CH4) el componente más significativo por unidad de producto.

El problema central es la ausencia de herramientas predictivas que permitan dosificar nutraceuticos inhibidores de metano de forma individualizada por animal. Sin predicción, la suplementación es subóptima: el exceso encarece costos operativos y el déficit perpetúa niveles altos de emisión, impidiendo cumplir metas de sostenibilidad y regulaciones ambientales emergentes.

Consecuencias económicas y ambientales:

- Exceso de nutraceutico: costo innecesario estimado en \$50–100 USD/vaca/año.
- Déficit de nutraceutico: persistencia de emisiones altas, perdiendo acceso a créditos de carbono valorados en ~\$30/ton CH4.
- Decisiones basadas en promedios generales, sin considerar raza, etapa de lactación ni historial individual.

Objetivo: Desarrollar un modelo de Machine Learning que prediga la intensidad de emisión de metano (g CH4/kg leche) por vaca individual, habilitando dosificación precisa de nutraceuticos y reducción medible de huella de carbono.

2. Hallazgos del Análisis Exploratorio de Datos (EDA)

El dataset contiene 73,000 registros de 100 vacas de 3 razas (Holstein, Jersey, Pardo Suizo), con 24 meses de datos (enero 2024 – diciembre 2025). Los cinco hallazgos que más impactaron el diseño del modelo:

#	Hallazgo	Métrica clave	Implicación para el modelo
1	Distribución bimodal de metano	Media 16.5 g/kg · 23% en nivel Alto (>25 g)	Dos perfiles de vaca: el modelo debe distinguirlos
2	Diferencias significativas por raza	Holstein 15.2 · Jersey 17.1 · P.Suizo 18.3 g/kg	Raza es variable predictora clave (no omitirla)
3	Correlación leche–metano	$r = -0.72$ (producción vs intensidad CH4)	Vacas más productivas emiten menos por kg de leche
4	Ventana crítica de lactación	Meses 8–14 de lactación concentran el 67% de alertas	Intervención preventiva debe ser antes del mes 7
5	Efecto medible del nutraceutico	$r = -0.61$ (dosis vs intensidad CH4)	Suplemento tiene efecto real y cuantificable

3. Modelos Evaluados y Elección del Modelo Final

Se siguió la metodología CRISP-ML(Q) en tres fases de modelado con un total de 7 modelos evaluados:

Avance	Modelo	RMSE CV	R ²	Latencia	Decisión
E3 — Baseline	Ridge Regression	0.7268	0.9688	< 1 ms	Baseline de referencia
E4	k-NN (k=5)	0.8121	0.9602	12 ms	Descartado — impracticable
E4	ElasticNet	0.7034	0.9681	2 ms	Descartado
E4	BayesianRidge	0.6832	0.9711	3 ms	Descartado
E4	RandomForest	1.4754	0.8714	8 ms	Descartado
E4 — Ganador	MLP Neural Network	0.6555	0.9746	5.7 ms	Avanza a ensamble E5
E5	VotingRegressor	0.6485	0.9752	6.7 ms	Descartado
★ E5 — FINAL	StackingRegressor	0.6117	0.9779	7.3 ms	★ MODELO SELECCIONADO

¿Por qué StackingRegressor?

- **RMSE = 0.6117:** Error promedio de ~0.6 g CH4/kg leche. Dentro del umbral de acción para ajuste de nutracéuticos.
- **R² = 0.9779:** El modelo explica el 97.8% de la varianza observada en emisiones.
- **Latencia 7.3 ms:** Respuesta en tiempo real; apto para uso en campo con conexión móvil.
- **Mejora –15.8%:** Sobre baseline Ridge E3. Estadísticamente significativa ($p < 0.0001$).
- **Arquitectura:** 3 modelos base (MLP + BayesianRidge + ElasticNet) cuyas predicciones alimentan un meta-modelo Ridge. Captura no-linealidades, robustez ante incertidumbre y regularización combinada.

4. Recomendaciones Clave para Implementar la Solución

Plazo	Acción	Responsable	Impacto esperado
0–3 meses	Desplegar API REST en GCP Cloud Run (Docker + pipeline_final_e5.pkl). SLO: P95 < 200 ms, uptime 99.5%.	Equipo ML + DevOps	Sistema productivo disponible
0–3 meses	Configurar IAM con 5 roles: admin, veterinario, pipeline SA, sponsor, auditor.	Arquitecto de seguridad	Acceso mínimo privilegio + trazabilidad
0–3 meses	Capacitar 2–3 operadores y veterinarios en uso del dashboard y lectura de alertas.	Project Manager	Adopción inmediata del sistema
3–6 meses	Reentrenamiento mensual automatizado con monitoreo KS-test de drift (trigger si $p < 0.05$).	MLOps	Modelo actualizado ante

			cambios estacionales
3–6 meses	Entregar Runbook operativo e IaC Terraform al sponsor (handoff formal).	Líder técnico	Continuidad sin dependencia del equipo
6–12 meses	Certificación de créditos de carbono usando el modelo como evidencia (Verra / Gold Standard).	Dirección + Sponsor	Nueva fuente de ingresos para el ganadero

Plataforma cloud recomendada: GCP — score 8.85/10 en matriz ponderada (vs AWS 8.55, Azure 8.50, IBM Watson 6.55). Cloud Run serverless a ~\$31 USD/mes, integración nativa sklearn en Vertex AI y \$300 USD de crédito inicial.

5. Análisis Costo–Beneficio

5.1 Supuestos Racionales

Para establecer cifras comparables y verificables, el análisis se basa en los siguientes supuestos:

- Escala de referencia: granja con 100 vacas en producción activa.
- Volumen de predicciones: ~500 consultas/día al API (5 por vaca, turno mañana y tarde).
- Precio del nutracéutico: \$2.00 USD/dosis. Dosis excedente evitada: 0.5 dosis/vaca/día en promedio = \$36.5 USD/vaca/año.
- Precio de leche: \$0.50 USD/kg. Mejora de producción estimada: +1% = +73 litros/vaca/año → ~\$25 USD/vaca/año.
- Precio crédito de carbono (mercado voluntario): \$30 USD/tonelada CO₂e. Reducción estimada: 50 ton CO₂e/año en hato de 100 vacas.
- Costo de mano de obra no incluido (el sistema no reemplaza personal, optimiza decisiones existentes).
- Horizonte de análisis: 12 meses. Los costos de desarrollo son no recurrentes; la infraestructura GCP es recurrente.

5.2 Costos por Fase CRISP-ML

Fase CRISP-ML	Componente	Tipo	Costo (USD)
Comprensión del negocio	Definición de objetivos y KPIs	No recurrente	\$0 (académico)
Preparación de datos	Adquisición, limpieza y validación de dataset	No recurrente	\$800
Modelado	Experimentación en Google Colab Pro	No recurrente	\$0 (créditos)
Evaluación	Validación estadística y pruebas de carga	No recurrente	\$0

Despliegue	Desarrollo, contenedorización e integración API	No recurrente	\$3,200
Infraestructura GCP	Cloud Run + Storage + Vertex AI (12 meses)	Recurrente	\$732 / año
Capacitación	Taller para veterinarios y personal de granja	No recurrente	\$500
Mantenimiento y ops	Reentrenamiento mensual + soporte técnico	Recurrente	\$720 / año
TOTAL AÑO 1			\$5,952

Nota: Los costos de infraestructura (\$732) y mantenimiento (\$720) son recurrentes. El costo recurrente anual a partir del año 2 = \$1,452 USD (sin costos de desarrollo).

5.3 Beneficios Proyectados (año 1, 100 vacas)

Fuente de beneficio	Descripción	Valor (USD)
Ahorro en suplementación	Dosificación óptima elimina exceso de nutracéutico (~0.5 dosis/vaca/día)	\$10,000
Eficiencia productiva	Mejora +1% en producción de leche por optimización nutricional	\$2,500
Créditos de carbono	~50 ton CO ₂ e reducidas, mercado voluntario (\$30/ton)	\$1,500
Reducción costos veterinarios	Menos visitas por problemas metabólicos asociados a metano alto	\$800
TOTAL BENEFICIOS		\$14,800

5.4 Interpretación de Beneficios Potenciales

- **Mejoras operativas:** El sistema elimina el ciclo de "dosis-error-corrección" que hoy realizan veterinarios empíricamente. La predicción individual por vaca reduce el tiempo de diagnóstico de horas a segundos por consulta.
- **Eficiencia y toma de decisiones más informada:** El dashboard en tiempo real permite al ganadero priorizar las 10–15 vacas de mayor riesgo en cada visita, en lugar de revisar el hato completo. Esto representa un ahorro de 2–3 horas de trabajo por visita semanal.
- **Nuevas oportunidades de negocio:** El modelo funciona como evidencia técnica para la certificación de créditos de carbono (protocolos Verra/Gold Standard). Una granja de 100 vacas puede generar ingresos adicionales de \$1,500–\$3,000 USD/año por venta de créditos en mercados voluntarios.
- **Mejora en la experiencia del cliente / ganadero:** Alertas automáticas en el dashboard notifican al veterinario antes de que una vaca entre en zona crítica de emisión. La intervención preventiva es menos costosa y más efectiva que la correctiva.

- **Escalabilidad y replicabilidad:** El sistema puede desplegarse en cualquier granja con datos históricos en < 4 semanas (Terraform IaC). A escala de cooperativa (1,000 vacas), el ROI se multiplica proporcionalmente con costos marginales mínimos.

ROI Año 1: 149% | Período de recuperación: ~4.8 meses | Beneficio neto: \$8,848 USD

6. Riesgos y Desafíos de la Solución

Los riesgos se clasifican en las cuatro categorías estándar de proyectos de ML en producción:

Categoría	Riesgo identificado	Probabilidad	Impacto	Estrategia de mitigación
DATOS	Sesgo en sensores de metano; registros faltantes en épocas de calor; distribución diferente entre razas sub-representadas (Jersey, Pardo Suizo)	Media	Alto	Pipeline de validación automática (Great Expectations). Reentrenamiento trimestral. Detección de drift con KS-test mensual.
DATOS	Drift estacional no capturado: el comportamiento en verano puede diferir significativamente del dataset de entrenamiento	Media	Medio	Validación cruzada temporal (GroupKFold por mes). Monitoreo de RMSE en producción vs umbral E3 (0.75).
SEGURIDAD / ATAQUES	Adversarial inputs en la API: peticiones maliciosas diseñadas para obtener predicciones extremas o engañar al sistema	Baja	Alto	Autenticación OAuth 2.0 + rate limiting 100 req/min. Validación de rangos físicamente plausibles (rechazo con HTTP 422).
SEGURIDAD / ATAQUES	Data poisoning en reentrenamiento: datos manipulados que degraden el modelo de forma silenciosa	Baja	Alto	Validación de schema y estadísticas antes de cada ciclo de reentrenamiento. Firma digital de modelos en GCS.
PRUEBA Y CONFIANZA	Baja adopción por parte de veterinarios: resistencia al cambio, desconfianza en la predicción automática	Alta	Crítico	Explicabilidad con SHAP values en cada predicción. Capacitación inicial + período de uso supervisado de 2 semanas.
PRUEBA Y CONFIANZA	Sobreconfianza en predicciones: el modelo se usa como única fuente de decisión sin validación del veterinario	Media	Medio	Intervalos de confianza visibles en dashboard. Alerta explícita: "predicción orientativa — requiere validación profesional".
CUMPLIMIENTO REGULATORIO	LFPDPPP: si se almacenan nombres de veterinarios o propietarios (personas físicas),	Media	Alto	Minimización de datos PII: trabajar con IDs anónimos. Aviso de privacidad +

	aplica la ley federal de protección de datos			Cloud DPA firmado con GCP.
CUMPLIMIENTO REGULATORIO	Auditabilidad para certificaciones de carbono: el modelo debe ser trazable y reproducible por auditores externos	Media	Alto	Versionado completo en MLflow. Registro inmutable de predicciones con hash del modelo. Documentación CRISP-ML(Q).